115 學年度大學部專題海報展

國立清華大學 資訊工程學系
National Tsing Hua University Department of Computer Science

Beautified Is Not Forged

分得出美顏與偽造、證據可以查核的人臉偵測系統

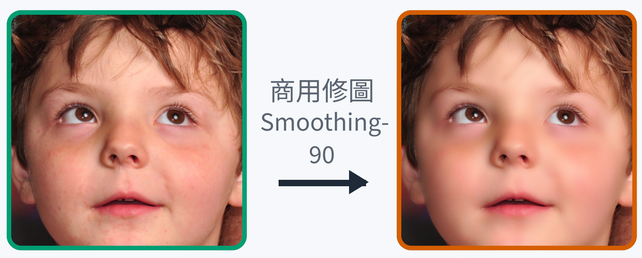
NTHU CS Capstone 2026　林沁瑩　陳柏融　游宸山

以前的偵測器只有 **real / fake** 兩個答案。經過美顏的真人照片兩邊都不是，於是被判成假的。我們把 **beautified** 做成第三類，每個判定都附上可以驗證的 evidence。

1 同一個美顏，讓 deepfake 偵測器犯兩種錯

17 個已發表偵測器，官方權重，逐張重跑

(a) 真人照片，磨皮後被判成假



	修圖前	修圖後
Effort	0.11 genuine	0.72 forged
Forensics Ad.	0.17 genuine	0.95 forged
GenD	0.19 genuine	0.97 forged
DFD-HR	0.27 genuine	0.94 forged

False alarm：四個偵測器全都從 genuine 翻成 forged。

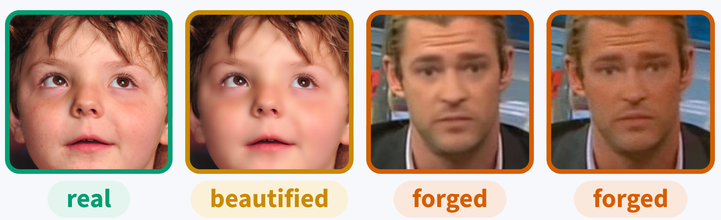
(b) 換臉影片，美顏後被放過



	美顏前	美顏後
Effort	0.97 forged	0.44 genuine
Forensics Ad.	1.00 forged	0.67 genuine
GenD	0.89 forged	0.70 genuine
DFD-HR	0.99 forged	0.74 forged

Miss：同樣四個，有三個讓這支換臉通過。

我們：三個答案 + evidence



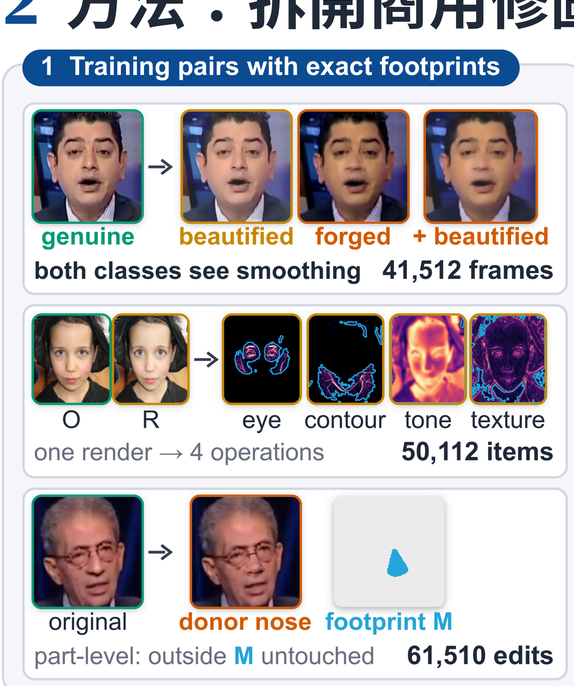
模型給 **forged** 和 **beautified** 兩個分數；forged 的判定只看 forged 分數，美顏分數再高也搶不走。evidence head 標出判定依據的部位。

16 / 17
已發表偵測器把磨皮真人判得比原圖更假

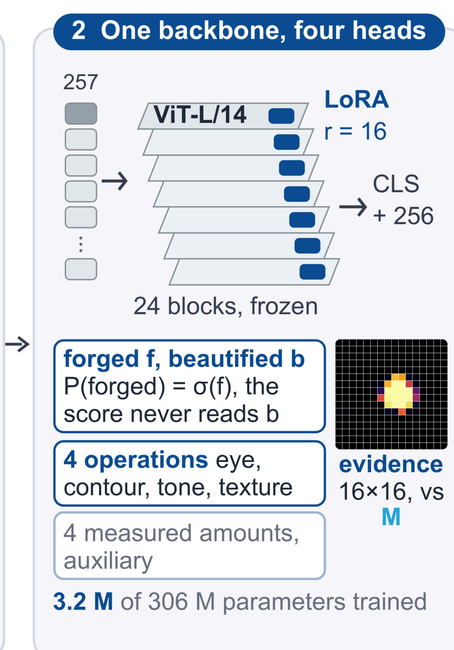
36–69%
其中 13 個在自己門檻下把這麼多磨皮真人判成 forged；

2 方法：拆開商用修圖，兩類都看過美顏，evidence 用精確 footprint 監督

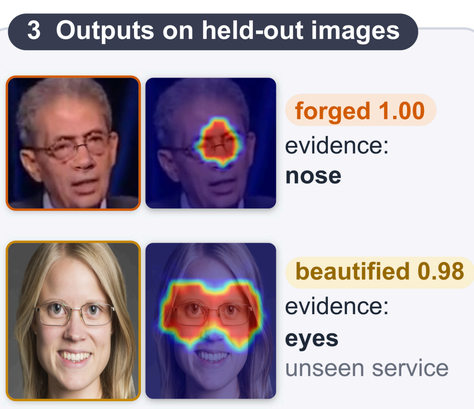
1 Training pairs with exact footprints



2 One backbone, four heads



3 Outputs on held-out images



The model's decision is fake (score 1.00). The evidence is concentrated on the nose (mean evidence 0.99). The score is the model's raw output, not a calibrated probability.
composed by code, checked

1 Data engine

商用 app 一次套好幾種美顏。用 optical flow 把形狀變化拆成 eye 和 contour，殘差用低通濾波拆成 tone 和 texture；每個分量都有像素對齊的原圖，footprint M 因此精確。18,734 張修圖 → 50,112 筆單一操作。

2 Model

CLIP ViT-L/14 全部凍結，只在 24 層 attention 加 LoRA r=16，訓練 3.16 M 個參數。CLS token 接 classification、operation、quantity 三個 head；256 個 patch token 接 evidence head，輸出 16×16 evidence map，用 M 監督。

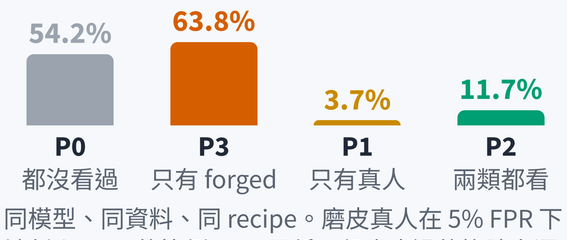
3 Output

evidence map 對到臉部部位，點名最強的一個。說明文字不用語言模型：程式依模型輸出組句，每句顯示前都經過規則檢查，不符合的句子不會出現。

3 成果

數字皆來自書面報告，主模型 seed 1

原因：訓練時哪一類看過磨皮



同模型、同資料、同 recipe。磨皮真人在 5% FPR 下被判 forged 的比例：P1 最低，但磨皮過的換臉多漏掉 51 點；P2 兩邊都好。

三類判定，以及訓練沒見過的修圖服務

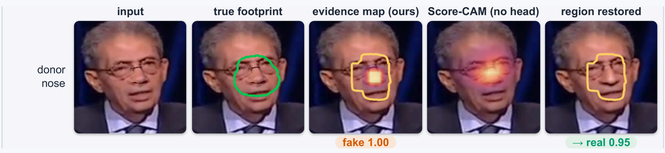
82.7 / 90.9 / 86.7
FF++ 測試集 recall，real / forged / beautified；美顏被判 forged 只有 4.3%

98.8%
阿里（訓練沒見過的修圖服務）的商用磨皮判成 beautified

≤ 0.8%
同一批修圖，任何操作、任何強度被判 forged 的上限

0.59 s
瀏覽器裡一張照片的時間（iPhone Safari 中位數），照片不上傳

evidence head 通過的測試，heat map 過不了



94%
還原標出的區域後，forged 判定消失（上限 94.1%）

45–57%
同一個測試，Grad-CAM / Score-CAM 這類 heat map

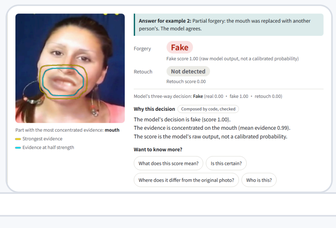
51–53%
VLM 自由描述盲配對 ≈ 擲硬幣；所以句子全由程式組成並檢查，361 / 361 通過

公平比較 只用同樣的 FF++ 訓練影片



Celb-DF-B 美顏後的 AUC，高於所有已發表偵測器；對 Effort、Forensics Adapter、SBI 的配對區間不含 0。一般換臉偵測則與最新方法打平。

整套系統在瀏覽器裡執行



MediaPipe 找臉 → ONNX Runtime 跑網頁版模型（EfficientNet-B4，67 MB）→ 程式畫出 evidence 輪廓、點名部位、組句並檢查。沒有伺服器，照片不離開裝置。

nothing uploaded　no server

限制與下一步

Reenactment 類偽造尚未涵蓋（Celeb-DF domain AUC 0.50 / 0.56）；20.8% 沒修過的 FFHQ 原圖被判成 beautified；黑白濾鏡（inkwell、moon）是最弱的一組；多種操作疊在同一張臉時，operation head 只點得出磨皮。

Code, scores, benchmark manifest

github.com/Doreen1113/beautified-not-forged

17 個偵測器的逐張分數、scorer、事前宣告與網頁 demo 都在 repo。